

逻辑回归

模型表示

先回顾一下线性回归, 线性回归通过历史数据拟合出一条直线, 用这条直线对新的数据进行预测, 线性回归公式如下:

$$y = \theta \cdot x + b$$


而对于逻辑回归来说, 其思想也是基于线性回归. 其公式如下:

$$h_{\theta}(x) = \frac{\exp(\theta \cdot x)}{1 + \exp(\theta \cdot x)} = \frac{1}{1 + \exp(-\theta \cdot x)}$$

其中,

$$y = \frac{1}{1 + \exp(-x)} = \text{sigmoid}(x) = \sigma(x)$$

被称为sigmoid函数.



sigmoid函数的值域为[0,1], 正好把线性输出变成概率, $h_{\theta}(x)$ 正好表示预测为positive的概率.

当 $h_{\theta}x > 0.5$ 时, 预测为positive

当 $h_{\theta}x < 0.5$ 时, 预测为nagtive

对于输出为positive和nagtive的概率分别为:

$$P(y = 1|x; \theta) = h_{\theta}(x) = \sigma(\theta \cdot x)$$

$$P(y = 0|x; \theta) = 1 - h_{\theta}(x) = 1 - \sigma(\theta \cdot x)$$

模型参数估计-极大似然估计

对于给定的训练数据集 $T = (x_1, y_x), (x_2, y_2), \dots, (x_N, y_N)$, 可以应用极大似然估计法估计模型参数 θ , 从而得到逻辑回归.

设

$$P(Y = 1|x) = h_{\theta}(x) = \pi(x)$$

$$P(Y = 0|x) = 1 - \pi(x)$$

那么

$$\pi(x) = \frac{\exp(\theta \cdot x)}{1 + \exp(\theta \cdot x)}$$

$$1 - \pi(x) = \frac{1}{1 + \exp(\theta \cdot x)}$$

一个事件发生和不发生的概率的比值称为该时间的几率, 则预测为positive的对数几率为:

$$\log\left(\frac{\pi(x)}{1 - \pi(x)}\right) = \theta \cdot x$$

似然函数为:

$$L(\theta) = \prod_{i=1}^N P(y^{(i)} | x^{(i)}; \theta)$$

也就是:

$$L(\theta) = \prod_{i=1}^N [\pi(x_i)]^{y_i} [1 - \pi(x_i)]^{1-y_i}$$

对数似然函数为:

$$l(\theta) = \log(L(\theta)) = \sum_{i=1}^N [y_i \log(\pi(x_i)) + (1 - y_i) \log(1 - \pi(x_i))]$$

$$l(\theta) = \sum_{i=1}^N [y_i \log\left(\frac{\pi(x_i)}{1 - \pi(x_i)}\right) + \log(1 - \pi(x_i))]$$

$$l(\theta) = \sum_{i=1}^N [y_i(\theta \cdot x) - \log(1 + \exp(\theta \cdot x_i))]$$

对 $l(\theta)$ 求极大值, 可以转化为求 $J(\theta)$:

$$J(\theta) = -\frac{1}{N}l(\theta)$$

的极小值。可以使用梯度下降法进行求解。